



Maestría en Ciencia de Datos (RVOE 2727)

Materia : Big Data & Data

- 4 Análisis de datos en Python.
 - 4.1 Conceptos básicos de Python.
 - 4.1.1 ¿Qué es y cómo instalar Python?
 - 4.1.2 Ejecución de código en Jupyter
 - 4.1.3 Sintaxis
 - 4.2 Análisis de datos en Python.
 - 4.2.1 Fuentes de datos
 - 4.2.2 Tipos de datos que se pueden recopilar
 - 4.2.3 Gestión, exploración y visualización efectiva de los datos



Ejemplo de aplicaciones del análisis de datos masivos en Python.

- Análisis de negocio: Analizar datos de ventas, marketing, finanzas y otras áreas de negocio para obtener información valiosa que ayude a tomar mejores decisiones.
- Análisis financiero: Analizar datos financieros, como precios de acciones, datos de mercado y carteras de inversión, para tomar decisiones de inversión más informadas.
- Análisis de redes sociales: Analizar datos de redes sociales, como tweets, publicaciones y
 comentarios, para comprender mejor las tendencias y el comportamiento del consumidor.
- Análisis de atención médica: Analizar datos de atención médica, como registros de pacientes, imágenes médicas y datos de ensayos clínicos, para mejorar la calidad de la atención y la investigación médica.
- Ciencia e ingeniería: Analizar datos científicos y de ingeniería, como datos de experimentos, simulaciones y modelos, para obtener nuevos conocimientos y desarrollar nuevas tecnologías.

¿Qué es python?

Python es un lenguaje de programación muy que se utiliza ampliamente en el análisis de datos masivos debido a su facilidad de uso, su amplia gama de bibliotecas especializadas y su capacidad para escalar a grandes conjuntos de datos.

Entorno de desarrollo: Herramientas como Anaconda, Jupyter, Google Colaboratory, que proporciona una distribución de Python preconfigurada con las bibliotecas necesarias para el análisis de datos, o es posible instalar Python y las bibliotecas individualmente utilizando pip, el administrador de paquetes de Python.



- Variables y tipos de datos: Familiarizarse con las variables y los diferentes tipos de datos que Python soporta, como números, cadenas, listas y diccionarios.
- Operadores matemáticos y lógicos: Entender los operadores básicos para realizar cálculos y comparaciones entre datos.
- Estructuras de control: Dominar el uso de condicionales (if, else) y bucles (for, while) para controlar el flujo de ejecución de un programa.
- Funciones: Aprender a crear y usar funciones para organizar el código y hacerlo más reutilizable.

Manipulación y limpieza de datos

- Lectura de datos: Aprender a leer datos desde diferentes fuentes como archivos de disintos formatos, bases de datos y APIs.
- Limpieza de datos: Identificar y corregir errores, valores inconsistentes y valores faltantes en los datos.
- Transformación de datos: Transformar los datos a un formato adecuado para el análisis, como normalizar las variables y crear nuevas variables a partir de las existentes.



- Manipulación de datos: Python tiene varios componentes para trabajar con datos, como Pandas y NumPy. Pandas es especialmente útil para la manipulación y análisis de datos estructurados, mientras que NumPy es excelente para operaciones numéricas eficientes.
- Procesamiento distribuido: Cuando los conjuntos de datos son grandes para caber en la memoria de una sola máquina, se necesita procesamiento distribuido, a lo cual existen frameworks como Apache Spark, Dask o Ray, que te permiten distribuir la carga de trabajo en múltiples nodos o procesadores.
- **Visualización de datos**: Es importante poder visualizar los datos para entenderlos mejor y comunicar los resultados de manera efectiva. Para esto, existen componentes como Matplotlib, Seaborn o Plotly para crear gráficos y visualizaciones interactivas.
- Apache Spark: Un framework de procesamiento distribuido que proporciona APIs en Python (PySpark), Java, Scala y SQL para procesar grandes conjuntos de datos en clústeres de computadoras.
- Dask: Una biblioteca de paralelización en Python que escala desde una sola máquina hasta clústeres de tamaño considerable. Se puede integrar bien con las bibliotecas de análisis de datos de Python, como Pandas y NumPy.
- Ray: Un framework de computación distribuida de código abierto para aplicaciones de aprendizaje automático y procesamiento de datos en Python.



Almacenamiento de datos: Para trabajar con grandes volúmenes de datos, es pertinente utilizar un sistema de almacenamiento adecuado, para implementar gestores de datos como MongoDB, PostgreSQL o Apache Cassandra, o sistemas de archivos distribuidos como Hadoop Distributed File System (HDFS) o Protocolos como S3.

Paralelismo y concurrencia: Para trabajar con grandes volúmenes de datos, es importante aprovechar al máximo los recursos de cómputo disponibles. Python tiene herramientas como asyncio y threading para programación concurrente, así como herramientas externas como multiprocessing para ejecutar tareas en paralelo.

Optimización de código: A medida que trabajas con conjuntos de datos más grandes, es importante escribir código eficiente para minimizar el tiempo de procesamiento. Esto implica conocer técnicas de optimización de código en Python, como vectorización, uso de estructuras de datos eficientes y evitar bucles innecesarios.

Entorno para utilizar Python

Jupyter es una aplicación web de código abierto que te permite crear y compartir documentos interactivos que contienen código, visualizaciones y texto explicativo. La palabra "Jupyter" es un acrónimo que combina los nombres de tres lenguajes de programación populares: Julia, Python y R, que son los principales lenguajes que Jupyter admite inicialmente.

Los documentos de Jupyter se denominan "cuadernos" (notebooks en inglés) y pueden contener celdas de código ejecutable, texto enriquecido, imágenes, enlaces y otros elementos multimedia. Esto hace que Jupyter sea una herramienta muy útil para el análisis de datos, ya que te permite escribir y ejecutar código Python (u otros lenguajes de programación) en el contexto de un documento interactivo.



La relación de Jupyter con el análisis de grandes volúmenes de datos con Python es significativa por varias razones:

- **Interactividad:** Jupyter proporciona un entorno interactivo donde puedes escribir y ejecutar código Python en tiempo real. Esto es útil para explorar y analizar datos de manera interactiva, ya que puedes ejecutar fragmentos de código y ver los resultados de inmediato.
- Visualización de datos: Jupyter es compatible con bibliotecas de visualización de datos
 populares como Matplotlib, Seaborn y Plotly, lo que te permite crear gráficos y visualizaciones
 interactivas directamente en tus cuadernos. Esto facilita la exploración y la comunicación de
 tus resultados de análisis de datos.
- Documentación: Los cuadernos de Jupyter te permiten combinar código, visualizaciones y
 texto explicativo en un solo documento. Esto es útil para documentar tus análisis de datos,
 compartir tus resultados con otros y crear informes técnicos o tutoriales.
- Soporte para diferentes lenguajes: Aunque Python es el lenguaje más comúnmente utilizado en los cuadernos de Jupyter, también es compatible con otros lenguajes de programación como R, Julia, Scala y muchos más. Esto te permite realizar análisis de datos utilizando una variedad de herramientas y bibliotecas en el mismo entorno.

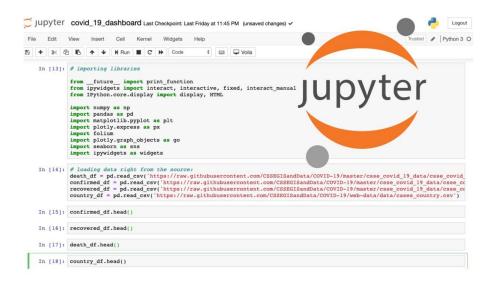
Ventajas de usar Jupyter para el análisis de datos

- Interactividad: Permite explorar y analizar datos de forma interactiva, ejecutando código y visualizando resultados de forma inmediata.
- Facilidad de uso: Es una herramienta intuitiva y fácil de aprender, incluso para principiantes en Python.
- Reproducibilidad: Los notebooks de Jupyter son documentos que contienen código, resultados y explicaciones, lo que permite compartir y reproducir análisis de forma sencilla.
- Flexibilidad: Permite combinar código, texto, imágenes y visualizaciones en un solo documento, lo que facilita la creación de informes y presentaciones.



Ejemplos de uso de Jupyter para el análisis de datos

- Limpieza y transformación de datos: Usar Jupyter para cargar datos, limpiarlos, transformarlos y prepararlos para el análisis.
- Análisis estadístico: Realizar análisis estadísticos descriptivos e inferenciales utilizando las bibliotecas de Python.
- Visualización de datos: Crear gráficos y visualizaciones para explorar los datos y comunicar tus hallazgos.
- Aprendizaje automático: Usar Jupyter para desarrollar modelos de aprendizaje automático para predecir resultados o clasificar datos.





```
import pandas as pd

# Cargar datos del INEGI
datos_inegi = pd.read_csv("https://www.inegi.org.mx/", compression="zip")

# Seleccionar variables de interés
datos_inegi = datos_inegi[["Entidad", "Sexo", "Poblacion_total"]]

# Calcular la población total por sexo y entidad
poblacion_total = datos_inegi.groupby(["Entidad",
"Sexo"])["Poblacion_total"].sum()

# Visualizar la población total por sexo en un gráfico de barras
import matplotlib.pyplot as plt plt.bar(datos_inegi["Entidad"],
poblacion_total)
plt.xlabel("Entidad")
plt.ylabel("Población total")
plt.ylabel("Población total")
plt.show()
```

En Python, hay varios tipos de datos que son comúnmente utilizados para el análisis de datos.

- Números enteros (int): Representan números enteros, como 1, 2, -5, entre otros
- Números de punto flotante (float): Representan números decimales, como 3.14, -0.001, entre otros
- Cadenas de caracteres (str): Representan texto, como "hola mundo", "Python es genial", entre otros
- Listas (list): Son colecciones ordenadas de elementos que pueden ser de diferentes tipos de datos. Por ejemplo, [1, 2, 3], ["a", "b", "c"], entre otros
- Tuplas (tuple): Son similares a las listas, pero son inmutables, es decir, no se pueden
 modificar una vez creadas. Por ejemplo, (1, 2, 3), ("a", "b", "c"), entre otros
- Diccionarios (dict): Son colecciones de pares clave-valor, donde cada valor está asociado con una clave única. Por ejemplo, {"nombre": "Juan", "edad": 30, "ciudad": "Madrid"}, entre otros
- Conjuntos (set): Son colecciones no ordenadas de elementos únicos. Por ejemplo, {1, 2, 3}, {"a", "b", "c"}, entre otros
- Booleanos (bool): Representan valores de verdad, es decir, verdadero (True) o falso (False).



Existen numerosas fuentes de datos masivos que pueden ser analizadas con Python para extraer información valiosa.

- Redes Sociales: Plataformas como X-Twitter, Facebook, LinkedIn y Reddit generan enormes
 cantidades de datos en forma de publicaciones, comentarios, conexiones de red, entre otros.
 Estos datos pueden ser analizados para comprender tendencias, opiniones de usuarios, patrones
 de comportamiento y más.
- Sensores IoT (Internet de las Cosas): Dispositivos IoT como sensores ambientales, medidores inteligentes, cámaras de vigilancia, entre otros, generan grandes volúmenes de datos en tiempo real. Estos datos pueden utilizarse para monitorear y predecir eventos, optimizar procesos industriales, mejorar la eficiencia energética y mucho más.
- Aplicaciones y Plataformas Web: Las aplicaciones y plataformas web recopilan datos de usuarios, como registros de acceso, clics, compras, búsquedas, entre otros. Estos datos pueden ser analizados para comprender el comportamiento del usuario, optimizar la experiencia del usuario, realizar análisis de mercado y más.
- Datos Geoespaciales: Datos geoespaciales, como imágenes de satélite, datos de GPS, mapas digitales, entre otros, pueden ser analizados para realizar análisis de ubicación, detección de cambios en el medio ambiente, planificación urbana, navegación y más.
- Datos de Transacciones Financieras: Los datos de transacciones financieras, como transacciones bancarias, transacciones con tarjetas de crédito, datos bursátiles, entre otros, pueden ser analizados para detectar fraudes, predecir tendencias del mercado, realizar análisis de riesgos, entre otros.
- Datos de Salud: Los datos de salud, que incluyen registros médicos electrónicos, datos de dispositivos médicos, datos de genómica, entre otros, pueden ser analizados para identificar patrones de enfermedades, descubrir tratamientos efectivos, realizar diagnósticos predictivos y más
- Datos de Medios de Comunicación: Los datos de medios de comunicación, como artículos de noticias, transmisiones de televisión, transmisiones de radio, entre otros, pueden ser analizados para realizar análisis de sentimientos, detectar tendencias de noticias, identificar temas de interés público y más.



Ejemplos de fuentes de grandes volúmenes de datos para análisis con Python:

Datos gubernamentales:

- https://en.www.inegi.org.mx/ (Instituto Nacional de Estadística y Geografía): Ofrece información estadística sobre México, incluyendo datos demográficos, económicos, sociales y ambientales
- https://datos.gob.mx/ : Portal de datos abiertos del gobierno de México, con información de diversas entidades públicas.

Datos financieros:

- https://finance.yahoo.com/ : Ofrece datos históricos y en tiempo real sobre acciones, bonos, divisas y otros instrumentos financieros.
- https://data.nasdaq.com/publishers/QDL : Base de datos de series temporales sobre diversos temas, incluyendo economía, finanzas y energía.

Datos de redes sociales:

- https://developer.twitter.com/en/docs/twitter-api : Permite acceder a datos de tweets, usuarios y hashtags.
- https://developers.facebook.com/docs/graph-api/ : Permite acceder a datos de usuarios, publicaciones, páginas y grupos de Facebook.

Datos de sensores:

- https://www.kaggle.com/ : Ofrece una variedad de conjuntos de datos para análisis, incluyendo datos de sensores.
- https://opendatacommons.org/ : Catálogo de conjuntos de datos abiertos, incluyendo datos de sensores.

Datos científicos:

- https://www.genome.gov/human-genome-project : Proyecto Genoma Humano, con información sobre la secuencia de ADN del genoma humano.
- https://www.sdss.org/ : Encuesta digital del cielo, con información sobre millones de objetos celestes.







Programming big data analysis: principles and solutions





Investigating the effects of learning activities in a mobile Python tutor for targeting multiple coding skills





Upgrading a high performance computing environment for massive data





D20: a distributed data object for parallel high-performance computing in Python





Springer Open

Open de Authoritis This action is destinated under the terms of the Creative Common Attribution 60 Hermaticnal Licenses

Application of the Creative Common Attribution 60 Hermaticnal Licenses

Application of the Creative Common Attribution 60 Hermaticnal Licenses

Application of the Creative Common Attribution 60 Hermaticnal Licenses

Application of the Creative Common Management of the Creative Common Hermaticnal Licenses

Application of the Creative Common Management of the Creative Common Hermaticnal Licenses

Application of the Creative Common Attribution 60 Hermaticnal Licenses

Application of the Creative Common Attribution 60 Hermaticnal Licenses

Application of the Creative Common Attribution 60 Hermaticnal Licenses

Application of the Creative Common Attribution 60 Hermaticnal Licenses

Application of the Creative Common Attribution 60 Hermaticnal Licenses

Application of the Creative Common Attribution 60 Hermaticnal Licenses

Application of the Creative Common Attribution 60 Hermaticnal Licenses

Application of the Creative Common Attribution 60 Hermaticnal Licenses

Application of the Creative Common Attribution 60 Hermaticnal Licenses

Application of the Creative Common Hermaticnal Licenses

Applicati



A survey of open source tools for machine learning with big data in the Hadoop ecosystem

Sara Landset Tanhi M. Khoshqoftaar, Aaron N. Richter, and Tawfig Hasanin

*Correspondence: arichter@fau.edu Florida Atlantic University; 777 Glades Road; Boca Ration,

Abstract With an ever

With an even-increasing amount of options, the task of selecting machine learning tools be by data and one offered. The available on bit here allurating and distribution, tools be by data and an offered and offered tools be offered and offered an

Keywords: Machine learning, Big data, Hadoop, Mahout, MLlib, SAMOA, H2O, Spark Flink Storm

Background

As the price of data storage has gone down and map preformance computers have become more widely accessable, we have seen an expansion of machine learning (ML) into a host of industries including finance, law enforcement, entertainment, commerce, and healthcare. As theoretical research is leveraged into practical tasks, machine learning tools are increasingly seen as not just useful, but integral to many business operations.



